



Seleção de Meta-Features com Algoritmo Genético

Projeto Final Individual — IC · UFAL

AUTOR

Renato Coca Terrazas Freire

ORIENTADOR

Prof. Lucas Amorim

DATA

Junho de 2026

Motivação e Objetivo

O Desafio Técnico

Contexto: Aprender qual algoritmo apresenta o melhor desempenho para um dataset específico.

Problema: O uso de **224 meta-features** introduz ruído e redundância, prejudicando a eficiência.

Hipótese: A seleção de um subconjunto ótimo reduz a complexidade e melhora a qualidade preditiva do meta-modelo.

Objetivo e Escopo

Objetivo Principal: Aplicar um **Algoritmo Genético (GA)** para identificar o subconjunto ideal de meta-features.

Ponto de Partida: Evolução do **Exemplo 3** da disciplina, expandindo a escala do experimento:

DATASETS

22 → 35

META-FEATURES

56 → 224



Foco em Otimização de Meta-modelos

Construção do Meta-Dataset

Fontes de Dados

Parte A: 20 datasets do Exemplo 3 (via OpenML).

Parte B: 15 datasets da suite OpenML-CC18.

35

DATASETS

224

META-FEATURES

Extração (pymfe)

Categorias de Features:

General

Statistical

Info-theory

Model-based

Complexity (C1, C2, F1, L1, etc.)

Medidas de Resumo (4 por feature):

Mean

SD

Min

Max

Total de 56 características base $\times$ 4 medidas = 224 meta-features.

Meta-Target

Algoritmos Base:

DecisionTree

SVM

KNN

LogReg

Perceptron

MLP

Variável Alvo

Acurácia do melhor algoritmo para cada dataset (problema de regressão).

 Meta-modelo treinado para prever a performance máxima alcançável.

Implementação do Algoritmo Genético

Estrutura & Fitness

REPRESENTAÇÃO

Cromossomo binário (224 bits)

MAPEAMENTO

1 = Incluir feature | 0 = Excluir

FUNÇÃO FITNESS

RMSE de Random Forest Regressor

VALIDAÇÃO

5-fold Cross-Validation

 Uso de **Fitness Caching** para evitar recomputação de indivíduos idênticos.

Operadores Evolutivos

SELEÇÃO

Torneio com $k=3$

CROSSOVER

Ponto único (Taxa: 0.8)

MUTAÇÃO

Bit-flip (Taxa: 0.05)

ESTRATÉGIA

Elitismo (Top-2 preservados)

Configuração & Execução

Indivíduos

30

Gerações

50

TEMPO MÉDIO

Aprox. 6 minutos de execução

AMBIENTE

Processamento paralelo para avaliação do fitness

Equilíbrio entre exploração do espaço de busca e custo computacional.

Convergência do Algoritmo Genético

-49,1%
REDUÇÃO DE FEATURES

📈 **-11,3% no RMSE**


0.08906 → 0.07902 (Fitness)

⚙️ **Seleção Robusta**

De 224 para 114 meta-features

A curva de fitness demonstra estabilização consistente após a 30ª geração, permitindo o descarte de redundâncias sem perda de qualidade preditiva.

Evolução do Fitness (RMSE) por Geração



Resultados: Baseline vs Após GA

CENÁRIO DE TESTE	FEATURES	RMSE (↓)	SPEARMAN (↑)
Exemplo 3 (Referência)	56	0.09078	0.30
Baseline (Expandido)	224	0.08768	0.76
Após GA (Otimizado)	114	0.07902	0.78

 Redução de Erro

-9,9% RMSE

Melhoria significativa na precisão do meta-modelo em relação ao baseline de 224 features.

 Ganho de Correlação

+153% Spearman

A expansão do meta-dataset (22 para 35 datasets) elevou a correlação de 0.30 para 0.76.

 Eficiência Dimensional

-49,1% Features

O Algoritmo Genético descartou metade das features sem perda de qualidade preditiva.

Análise: Especialização por Algoritmo

FOCO DE OTIMIZAÇÃO

O Algoritmo Genético foi configurado com o objetivo de minimizar o erro (RMSE) especificamente para o meta-modelo de **Logistic Regression (LR)**.

 *A fitness function baseia-se na performance do meta-alvo definido.*

✅ Beneficiados (+)

- ▲ LogisticRegression
- ▲ SVM
- ▲ MLP

❌ Prejudicados (-)

- ▼ DecisionTree
- ▼ KNN
- ▼ Perceptron



Conclusão Analítica: A seleção ótima de meta-features é dependente do algoritmo-alvo. Não existe um subconjunto universalmente superior para todos os meta-modelos.

GA vs Importância por Random Forest

☰ Ranking de Importância (RF)

1	l3.mean	SELECIONADA
2	f1v.min	SELECIONADA
3	l3.max	DESCARTADA
4	f1v.max	DESCARTADA
5	l1.max	DESCARTADA

🧠 Lógica de Seleção (GA)

🔍 Detecção de Redundância

As features l3.max, f1v.max e l1.max foram descartadas apesar do ranking alto por serem **altamente correlacionadas** com as duas primeiras.

📦 Grupo de Complexidade

Todas as Top-5 pertencem ao grupo *complexity*. O GA identificou que apenas as duas primeiras eram necessárias para capturar a informação relevante.

"O Algoritmo Genético realiza uma seleção mais sofisticada que o ranking simples, otimizando o conjunto como um todo e não apenas features isoladas."

Significância Estatística – Teste de Wilcoxon



Resultado do Teste

P-VALOR CALCULADO

0.232

⚠ Não Significativo ($p > 0.05$)

Teste Estatístico

Wilcoxon Signed-Rank

Comparação

Baseline vs. Pós-GA

Validação

10-fold Cross-Validation



Análise de Poder

Embora o Algoritmo Genético tenha reduzido o erro médio, a melhoria não atingiu o limiar de significância estatística de 5%.

Limitação do Meta-dataset

O tamanho da amostra (N=35 datasets) limita o poder estatístico do teste, dificultando a rejeição da hipótese nula apesar da tendência observada.



A tendência de melhora é consistente em todas as folds

Com a expansão do meta-dataset para um volume maior de dados, espera-se que a diferença de performance se torne estatisticamente robusta.

Conclusões e Trabalhos Futuros

01

Otimização e Eficiência do Meta-modelo

A expansão para 224 features elevou a correlação de Spearman de **0.30 para 0.76**. O Algoritmo Genético reduziu **49,1% das features** (114 selecionadas) garantindo uma melhoria de 11,3% no RMSE.

02

Superioridade na Detecção de Redundância

O GA superou rankings simples de importância ao descartar automaticamente features altamente correlacionadas no grupo **complexity**, realizando uma seleção mais sofisticada que prioriza a diversidade de informação.

03

Especialização Algorítmica Confirmada

A seleção ótima de meta-features é **específica para o algoritmo-alvo** (meta-modelo). Não existe um subconjunto universal, reforçando a necessidade de otimização dedicada para cada tarefa de meta-aprendizagem.

04

Limitações e Propostas Futuras

A amostra de 35 datasets limitou a significância estatística ($p=0.232$). Trabalhos futuros devem **ampliar o meta-dataset** e explorar variantes de GA multiobjetivo para equilibrar erro e complexidade do modelo.